



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ
UNIVERSITY OF PIRAEUS

Εργασία 3 - Επεξεργασία Φυσικής Γλώσσας (Επισημείωση Ακολουθιών / Sequence Labeling)

Φαίδων Γραμματικόπουλος

Μάθημα: Επεξεργασία Φυσικής Γλώσσας
Διδάσκων: Ε. Σταματάτος

MSc in Artificial Intelligence
University of Piraeus & NCSR "DEMOKRITOS", Greece

Μάιος 2026

Εισαγωγή

Στην παρούσα εργασία μελετώνται τρεις πτυχές της Επεξεργασίας Φυσικής Γλώσσας (NLP) με εστίαση στην ακολουθιακή επισημείωση (sequence labeling):

- Λεπτομερής εκπαίδευση (fine-tuning) προ-εκπαιδευμένων γλωσσικών μοντέλων (BERT, RoBERTa) σε επίπεδο token
- Σύγκριση τριών εργασιών ακολουθιακής επισημείωσης: αναγνώριση οντοτήτων (NER), μέρος λόγου (POS) και τεμαχισμός (chunking)
- Zero-shot αναγνώριση οντοτήτων με μεγάλα γλωσσικά μοντέλα (Llama, GLM, Gemini)

Στο **Μέρος Α** εκπαιδεύεται το προ-εκπαιδευμένο *bert-base-uncased* με κεφαλή ταξινόμησης token στο *CoNLL-2003 English* για NER. Αναφέρονται μέση τιμή $\pm$ τυπική απόκλιση σε τέσσερις μετρικές (token-level micro/macro accuracy και entity-level micro/macro F1), καθώς και ο χρόνος εκπαίδευσης. Συζητείται η διαφορά μεταξύ μετρικών token-level και entity-level για NER, πραγματοποιείται ανάλυση σφαλμάτων σε μία πραγματική λανθασμένα επισημειωμένη πρόταση του test set (≥ 10 tokens) καθώς και σε μία επινοημένη πρόταση εκτός corpus.

Στο **Μέρος Β** επαναλαμβάνεται το πλέγμα του Μέρους Α σε τέσσερις παραλλαγές της ίδιας αρχιτεκτονικής. Πρώτον, παγώνονται τα βάρη του κωδικοποιητή BERT και εκπαιδεύεται μόνο η κεφαλή ταξινόμησης, ώστε να αποτιμηθεί η συνεισφορά του fine-tuning του κορμού. Δεύτερον και τρίτον, η ίδια αρχιτεκτονική εκπαιδεύεται στα tag sets των εργασιών POS tagging και chunking, για να ελεγχθεί η μεταφορά της σε άλλες εργασίες ακολουθιακής επισήμανσης. Τέλος, το *bert-base-uncased* αντικαθίσταται από *roberta-base* (με *add_prefix_space=True* στον tokenizer για σωστή byte-level BPE τμηματοποίηση) και επαναλαμβάνεται το Μέρος Α για άμεση σύγκριση.

Στο **Μέρος Γ** εξετάζεται η εναλλακτική προσέγγιση χωρίς εκπαίδευση: εφαρμόζεται zero-shot αναγνώριση οντοτήτων στα πρώτα 200 παραδείγματα του test split του *CoNLL-2003*, μέσω decoder only LLMs που καλούνται μέσω HTTP. Δοκιμάζονται τα *Llama-3.1-8B-Instant* και *Llama-3.3-70B-Versatile*. Συγκρίνονται τρεις παραλλαγές προτροπής (μινιμαλιστική, αυστηρή JSON, και με γλωσσάρι ετικετών) με κοινή μηχανή ανάλυσης απαντήσεων και κατασκευής ετικετών ανά token. Ως bonus επεκτάσεις εκτελείται το ίδιο πρωτόκολλο με τα *GLM-4.7-Flash* (Z.ai) και *Gemini-2.5-Flash-Lite*, και όλα τα μοντέλα συγκρίνονται μεταξύ τους.

Ο κώδικας υλοποιήθηκε σε Python και είναι διαθέσιμος στο ανοικτό αποθετήριο στο github: [<https://github.com/Fgram-devAI/nlp-ncsr-task3>].

Κεφάλαιο 1

Μέρος A - Baseline NER-BERT

1.1 Baseline fine-tuning του bert-base-uncased

Εκπαιδεύεται το προ-εκπαιδευμένο *bert-base-uncased* (12 Transformer encoder layers, ≈ 110 M παράμετροι) με κεφαλή ταξινόμησης token (*BertForTokenClassification*) στο σύνολο δεδομένων *CoNLL-2003 English* (train/valid/test = 14,041/3,250/3,453 προτάσεις) για την εργασία αναγνώρισης οντοτήτων (NER) σε 9 BIO κλάσεις (B-PER, I-PER, B-ORG, I-ORG, B-LOC, I-LOC, B-MISC, I-MISC, O).

Οι υπερ-παράμετροι είναι εκείνες που ορίζονται στο σενάριο της εκφώνησης: 3 εποχές, batch size 8, learning rate $1e-5$, optimizer AdamW. Το σενάριο εκτελείται τρεις φορές με seeds [42, 43, 44] ώστε να εκτιμηθεί η ευαισθησία της επίδοσης στην τυχαία αρχικοποίηση της κεφαλής και τη σειρά παρτίδων. Όλα τα πειράματα του Μέρους A εκτελούνται τοπικά σε Apple-Silicon M4 Pro Max (MPS).

Στον Πίνακα 1.1 παρουσιάζονται μέση τιμή $\pm$ τυπική απόκλιση σε τέσσερις μετρικές (token-level micro / macro accuracy και entity-level micro / macro F1 μέσω *segeval*) καθώς και ο χρόνος εκπαίδευσης ανά seed.

Μετρική	Μέση τιμή	Τυπική απόκλιση
Token-level micro accuracy	0.9787	0.0006
Token-level macro accuracy	0.9051	0.0036
Entity-level micro F1	0.8977	0.0039
Entity-level macro F1	0.8810	0.0042
Χρόνος εκπαίδευσης ανά σπόρο (s)	3255.6	134.9

Πίνακας 1.1: Baseline NER-BERT στο test split του *CoNLL-2003*, μέσος όρος $\pm$ τυπική απόκλιση πάνω σε seed [42, 43, 44]. Ο χρόνος εκπαίδευσης αντιστοιχεί σε ≈ 54 λεπτά ανά seed σε M4 Pro Max MPS.

Τρεις παρατηρήσεις: (α) οι τυπικές αποκλίσεις είναι πολύ μικρές (το μέγιστο 0.0042 στο entity-level macro F1), δηλαδή η εκπαίδευση είναι σταθερή και η σύγκριση με μεταγενέστερα ερωτήματα μπορεί να γίνει με ασφάλεια στη μέση τιμή· (β) ο χρόνος εκπαίδευσης διαφέρει αισθητά μεταξύ seeds (3166.8, 3410.9, 3189.1 δευτερόλεπτα) λόγω θερμικής διακύμανσης της κονσόλας και background load του macOS· (γ) η απόσταση των ≈ 8 ποσοστιαίων μονάδων μεταξύ token-level micro accuracy (97.87%) και entity-

level micro F1 (89.77%) είναι αρκετά μεγάλη ώστε να αξίζει ξεχωριστή συζήτηση --- βλ. §1.2.

1.2 Token-level έναντι Entity-level μετρικών για NER

Token-level accuracy και entity-level F1 αξιολογούν διαφορετικά πράγματα, και η πρώτη δίνει συστηματικά πιο ραισιόδοξη εικόνα όταν η εργασία είναι NER:

- **Token-level** μετρά κάθε token ξεχωριστά. Επειδή η συντριπτική πλειονότητα των tokens σε ένα NER κείμενο φέρει την ετικέτα O ($\approx 83\%$ στο test split του CoNLL-2003), ένας ταξινομητής που προβλέπει πάντα O επιτυγχάνει ήδη $\approx 83\%$ token accuracy χωρίς να αναγνωρίζει καμία οντότητα.
- **Entity-level F1** (μέσω *seqeval*) αξιολογεί τα πλήρη spans οντοτήτων: η πρόβλεψη (B-PER, I-PER) για το "John Smith" μετράει ως μία σωστή οντότητα μόνο όταν και τα δύο tokens έχουν προβλεφθεί κατά σειρά και τύπο. Όλα τα σφάλματα ορίου (π.χ. πρόβλεψη του "Smith" ως I-PER όταν στην αλήθεια ήταν αρχή νέας οντότητας) και τα σφάλματα τύπου (B-LOC αντί B-ORG) χρεώνονται ως πλήρεις αποτυχίες της οντότητας.

Επιπλέον, η διάκριση macro έναντι micro βαραίνει διαφορετικά τις σπάνιες κατηγορίες: η macro επίδοση δίνει ίσο βάρος σε κάθε τύπο οντότητας, οπότε η σπάνια κατηγορία MISC (η οποία εμφανίζεται ≈ 8 φορές λιγότερο από PER στο CoNLL training set) επηρεάζει το macro F1 το ίδιο όσο η συχνή PER. Στα αποτελέσματα του Ερωτήματος 1 η token-level micro accuracy (97.87%) ξεπερνά την entity-level micro F1 (89.77%) κατά ≈ 8 ποσοστιαίες μονάδες, όπου αυτή είναι ουσιαστικά η "οφθαλμαπάτη" του O-dominance.

Συμπερασματικά, η entity-level micro F1 του *seqeval* είναι ο σωστός μετρητής για άμεση σύγκριση μοντέλων NER, ενώ η token-level accuracy έχει χρησιμότητα μόνο ως sanity check (π.χ. για να διαπιστωθεί ότι το μοντέλο δεν έχει αποτύχει ολοκληρωτικά). Στις συγκρίσεις του Μέρους B και του Μέρους Γ αναφέρουμε και τις τέσσερις μετρικές, αλλά η συζήτηση συγκεντρώνεται στην entity-level micro F1.

1.3 Ερώτημα 3 - Ανάλυση σφαλμάτων

Για τη συγκεκριμένη εκπαίδευση με seed 42 (test entity-level micro-F1 = 0.9004, συμβατό με τη μέση τιμή 0.8977 του Πίνακα 4.1) αποθηκεύονται οι προβλέψεις του μοντέλου ανά πρόταση στο test set. Από τις 346 υποψήφιες προτάσεις με ≥ 10 tokens που περιέχουν τουλάχιστον ένα λάθος tag, επιλέγεται αυτή με τη χαμηλότερη per-sentence entity-level F1.

1.3.1 Πραγματική πρόταση του test set που αποτυγχάνει

Η επιλεγμένη πρόταση (test index 76, 11 tokens) έχει per-sentence entity-level F1 ίση με 0. Ο Πίνακας 4.2 δείχνει token-προς-token την αληθή ετικέτα, την πρόβλεψη του μοντέλου και αν είναι σωστή.

Token	Αληθές tag	Πρόβλεψη	Σωστό;
Results	O	O	✓
of	O	O	✓
Asian	B-MISC	B-MISC	✓
Cup	I-MISC	I-MISC	✓
group	O	I-MISC	×
C	O	I-MISC	×
matches	O	O	✓
played	O	O	✓
on	O	O	✓
Friday	O	O	✓
:	O	O	✓

Πίνακας 1.2: Ανάλυση σφαλμάτων στην πρόταση “Results of Asian Cup group C matches played on Friday :” (seed 42). Σωστά 9/11 tokens, αλλά entity-level F1 = 0.

Η αληθής οντότητα είναι η αθλητική διοργάνωση “Asian Cup” (τύπος MISC, span δύο tokens). Το μοντέλο αναγνωρίζει σωστά την αρχή και τον τύπο της οντότητας (*Asian*=B-MISC, *Cup*=I-MISC), αλλά επεκτείνει εσφαλμένα το όριο της φράσης, συνεχίζοντας με I-MISC στα tokens *group* και *C*. Ενδεχομένως, το μοντέλο “διαβάζει” τη φράση ως “Asian Cup group C” (τη συγκεκριμένη ομάδα του τουρνουά). Πρόκειται για ένα κλασικό **σφάλμα ορίου (boundary error)**: μόνο 2 από τα 11 tokens είναι λάθος, οπότε η token-level accuracy παραμένει υψηλή ($9/11 = 81.8\%$), αλλά η προβλεπόμενη οντότητα “Asian Cup group C” δεν ταυτίζεται span-προς-span με τη χρυσή “Asian Cup”. Συνεπώς η χρυσή οντότητα μετράει ως false negative και η προβλεφθείσα ως false positive, ρίχνοντας την entity-level F1 της πρότασης στο 0. Είναι ακριβώς η “οφθαλμαπάτη της O-dominance” που συζητήθηκε στο §1.2, σε μία και μόνη πρόταση.

1.3.2 Επινοημένη πρόταση εκτός corpus

Ως δεύτερο πείραμα, δίνεται στο τελικό μοντέλο μία επινοημένη πρόταση δημοσιογραφικού ύφους (15 tokens), φτιαγμένη ώστε να περιέχει εφευρημένες ονομαστικές οντότητες (που το μοντέλο δεν μπορεί να έχει απομνημονεύσει) μαζί με δημώνυμα και τοπωνύμιο:

Το μοντέλο επισημειώνει σωστά και τα 15 tokens ($F1 = 1.0$). Αξιοσημείωτα: (α) οι δύο εφευρημένες εταιρείες *Helios* και *KronosAI* ταξινομούνται ορθά ως B-ORG παρότι δεν εμφανίζονται στα δεδομένα εκπαίδευσης, συνεπώς το μοντέλο στηρίζεται στα συμφραζόμενα (“startup”, “rival”, το ρήμα “bought”) και στην κεφαλαιοποίηση, όχι σε απομνημόνευση. (β) τα γεωγραφικά επίθετα/οντότητες *Greek* και *Bavarian* ταξινομούνται ως B-MISC, σύμφωνα με τη σύμβαση του CoNLL-2003 για επίθετα εθνικότητας/προέλευσης. (γ) το *Berlin* ως B-LOC. Το ότι ένα εφευρημένο όνομα όπως το *Helios*, που το BERT τμηματοποιεί σε υπο-tokens αναγνωρίζεται σωστά ως οντότητα, δείχνει ότι η fine-tuned κεφαλή έχει μάθει ένα γενικεύσιμο, συντακτικά οδηγούμενο μοτίβο NER και όχι απλώς ένα λεξικό γνωστών ονομάτων.

Token	Αληθές tag	Πρόβλεψη	Σωστό;
Greek	B-MISC	B-MISC	✓
startup	O	O	✓
Helios	B-ORG	B-ORG	✓
bought	O	O	✓
Bavarian	B-MISC	B-MISC	✓
rival	O	O	✓
KronosAI	B-ORG	B-ORG	✓
in	O	O	✓
Berlin	B-LOC	B-LOC	✓
yesterday	O	O	✓
for	O	O	✓
2	O	O	✓
billion	O	O	✓
euros	O	O	✓
.	O	O	✓

Πίνακας 1.3: Προβλέψεις του μοντέλου (seed 42) στην επινοημένη πρόταση “Greek startup Helios bought Bavarian rival KronosAI in Berlin yesterday for 2 billion euros.”, 15/15 tokens σωστά, entity-level F1 = 1.0.

1.4 Ευθυγράμμιση ετικετών και η ειδική τιμή -100

Το BERT χρησιμοποιεί WordPiece tokenization, οπότε μία λέξη του CoNLL μπορεί να σπάσει σε πολλαπλά υπο-tokens. Για παράδειγμα, η λέξη “Helios” τμηματοποιείται σε [“he”, “##lio”, “##s”], ενώ το CoNLL κορμός μας δίνει μία ετικέτα ανά λέξη (one tag per word). Η συνάρτηση *align_label* του εκπαιδευτικού σεναρίου ευθυγραμμίζει αυτές τις λεξιλογικές ετικέτες με τα υπο-tokens του BERT χρησιμοποιώντας το *word_ids()* του fast tokenizer:

- Special tokens του BERT (CLS, SEP, padding) έχουν *word_id* *None* και λαμβάνουν ετικέτα -100 .
- Το πρώτο υπο-token κάθε λέξης λαμβάνει την αυθεντική ετικέτα του CoNLL για αυτή τη λέξη.
- Τα συνεχόμενα υπο-tokens της ίδιας λέξης (ίδιο *word_id* με το προηγούμενο) λαμβάνουν επίσης -100 .

Η ειδική τιμή -100 είναι η default *ignore_index* της *CrossEntropyLoss* του PyTorch: όλες οι θέσεις με αυτή την ετικέτα αγνοούνται κατά τον υπολογισμό του loss (η βαθμίδα δεν διαδίδεται από εκεί) και αγνοούνται και κατά την αξιολόγηση μέσω της ίδιας μάσκας (*labels* $\neq -100$). Έτσι επιτυγχάνονται δύο πράγματα:

1. **Καθαρό σήμα εκπαίδευσης.** Το μοντέλο εκπαιδεύεται μόνο στις θέσεις που έχουν πραγματικό label από τον άνθρωπο. Padding, CLS, SEP δεν μολύνουν το loss με spurious patterns.

2. **Συνέπεια εκπαίδευσης-αξιολόγησης.** Τόσο η εκπαίδευση όσο και η αξιολόγηση χρησιμοποιούν τις ίδιες ``ενεργές`` θέσεις (πρώτο υπο-token κάθε λέξης), οπότε η μετρική στο test set είναι ευθεία απεικόνιση του τι ``βλέπει`` το μοντέλο κατά την εκπαίδευση.

Σχεδιαστική σημείωση: το να εκπαιδεύεται μόνο το πρώτο υπο-token κάθε λέξης (αντί π.χ. να αντιγράφεται η ίδια ετικέτα σε όλα τα υπο-tokens, ή να χρησιμοποιείται mean pooling πάνω από όλα τα υπο-tokens μιας λέξης πριν την ταξινόμηση) είναι η πιο συντηρητική και ευρέως υιοθετημένη επιλογή στη βιβλιογραφία NER με Transformers και αυτή που υιοθετείται συνολικά στα Μέρη Α και Β της παρούσας εργασίας.

Κεφάλαιο 2

Μέρος Β - Παραλλαγές της αρχιτεκτονικής

Στο Μέρος Β επαναλαμβάνεται το πλέγμα του Μέρους Α σε τέσσερις παραλλαγές της ίδιας αρχιτεκτονικής *BERT* + κεφαλή ταξινόμησης *token*: (Q5) πάγωμα του κωδικοποιητή, (Q6) αλλαγή εργασίας σε POS tagging, (Q7) αλλαγή εργασίας σε text chunking, και (Q8) αντικατάσταση του κορμού με *roberta-base*. Κάθε παραλλαγή εκτελείται τρεις φορές με seeds [42, 43, 44] και αναφέρεται μέση τιμή $\pm$ τυπική απόκλιση (δείγματος).

Σημείωση για το υλικό. Οι μετρικές ακρίβειας είναι ανεξάρτητες υλικού και άμεσα συγκρίσιμες μεταξύ όλων των ερωτημάτων. Ο χρόνος εκπαίδευσης, αντίθετα, συλλέχθηκε σε ετερογενές υλικό: το Q5 σε Colab T4 (*cuda*), το Q6 σε ανάμεικτο υλικό (seed 42 τοπικά σε MPS, seeds 43-44 σε T4), ενώ τα Q7/Q8 τοπικά σε MPS, οπότε οι χρόνοι είναι μόνο χονδρικά συγκρίσιμοι.

2.1 Πάγωμα του κωδικοποιητή BERT

Αλλαγές στον κώδικα. Μετά την κατασκευή του *BertForTokenClassification*, παγώνονται όλες οι παράμετροι του κορμού BERT θέτοντας *requires_grad = False* σε κάθε παράμετρο του *model.bert*, ώστε ο *optimizer* να ενημερώνει μόνο τα βάρη της γραμμικής κεφαλής ταξινόμησης. Δεν αλλάζει τίποτα άλλο στο pipeline (ίδιο *align_label*, ίδιες υπερ-παράμετροι).

Αριθμός παραμέτρων. Από τις συνολικά 108,898,569 παραμέτρους του μοντέλου, παγώνονται οι 108,891,648 (ο κωδικοποιητής BERT) και μένουν εκπαιδευσιμες μόνο 6,921, δηλαδή το 0.0064% του μοντέλου. Οι 6,921 αντιστοιχούν στη γραμμική κεφαλή: $768 \times 9 = 6,912$ βάρη συν 9 bias, για τις 9 NER κλάσεις.

Σύγκριση με το Ερώτημα 1. Το πάγωμα του κορμού καταρρέει την επίδοση: η entity-level micro F1 πέφτει από 0.8977 (Q1, πλήρες fine-tuning) σε 0.2487 απώλεια ≈ 65 ποσοστιαίων μονάδων. Ακόμη και η token-level micro accuracy πέφτει στο 0.8502, οριακά πάνω από το $\approx 83\%$ που πετυχαίνει ένας ταξινομητής “πάντα-Ο” (§1.2). Η ερμηνεία είναι ότι τα contextualized embeddings του προ-εκπαιδευμένου BERT, χωρίς προσαρμογή

Μετρική	Μέση τιμή	Τυπική απόκλιση
Token-level micro accuracy	0.8502	0.0016
Token-level macro accuracy	0.2014	0.0061
Entity-level micro F1	0.2487	0.0152
Entity-level macro F1	0.1962	0.0120
Χρόνος εκπαίδευσης ανά σπόρο (s)	1607.5	1.2

Πίνακας 2.1: Q5 - παγωμένος BERT, μόνο η κεφαλή εκπαιδεύεται. Μέσος όρος $\pm$ τυπική απόκλιση πάνω σε seeds [42, 43, 44] (Colab T4).

(fine-tuning) στα δεδομένα του CoNLL, δεν είναι γραμμικά διαχωρίσιμα στις NER κλάσεις: μία απλή γραμμική κεφαλή (linear probe) πάνω σε ``παγωμένα`` χαρακτηριστικά δεν επαρκεί. Συμπεραίνεται ότι το μεγαλύτερο μέρος της επίδοσης NER προέρχεται από το ίδιο το fine-tuning του κορμού και όχι μόνο από την κεφαλή. Η εκπαίδευση είναι $\approx 2\times$ ταχύτερη (1607 έναντι 3255 s), εν μέρει επειδή δεν διαδίδεται βαθμίδα μέσα από τον κωδικοποιητή και εν μέρει λόγω του διαφορετικού υλικού (T4 έναντι MPS).

2.2 POS tagging

Αλλαγές στον κώδικα. Η εργασία αλλάζει από NER σε POS tagging αντικαθιστώντας τη στήλη ετικετών του CoNLL από *ner* σε *pos* (*tag_column* = "pos") και αυξάνοντας τον αριθμό κλάσεων από 9 σε 45 (*num_labels* = 45, το tag set Penn Treebank του CoNLL-2003). Οι entity-level μετρικές παραλείπονται: το POS tagging δεν έχει έννοια ``span οντότητας``, οπότε το *seqeval* δεν εφαρμόζεται (υπόδειξη 6 της εκφώνησης). Τα υπόλοιπα (tokenizer, *align_label*, υπερ-παράμετροι) μένουν αμετάβλητα.

Μετρική	Μέση τιμή	Τυπική απόκλιση
Token-level micro accuracy	0.9411	0.0004
Token-level macro accuracy	0.8521	0.0024
Χρόνος εκπαίδευσης ανά σπόρο (s)	4096.5	620.6

Πίνακας 2.2: Q6 - POS tagging, μέσος όρος $\pm$ τυπική απόκλιση πάνω σε seeds [42, 43, 44]. Ο χρόνος εκπαίδευσης μεικτός: seed 42 σε MPS (3380 s), seeds 43-44 σε Colab T4 (≈ 4455 s έκαστο), οπότε η μεγάλη τυπική απόκλιση αντικατοπτρίζει το υλικό, όχι αστάθεια της εκπαίδευσης.

Σχόλιο. Η token-level micro accuracy του POS (0.9411) είναι αισθητά χαμηλότερη από εκείνη του NER (0.9787 στο Q1). Αυτό δεν σημαίνει ότι το POS είναι ``δυσκολότερο`` με την απόλυτη έννοια: αντανακλά κυρίως το ότι το POS έχει 45 πυκνά κατανεμημένες κλάσεις (όπου σχεδόν κάθε token φέρει ένα μη-τετριμμένο tag), ενώ στο NER η συντριπτική πλειονότητα των tokens είναι η εύκολη κλάση O. Η macro accuracy 0.8521 δείχνει καλή κάλυψη και των σπανιότερων POS κατηγοριών.

2.2.1 POS -Ανάλυση σφαλμάτων

Για το seed 42 (token-level micro accuracy 0.9411), από τις 982 υποψήφιες προτάσεις με ≥ 10 tokens και ≥ 1 λάθος, επιλέγεται αυτή με τη χαμηλότερη per-sentence accuracy. Επειδή στο POS δεν υπάρχουν spans, το κριτήριο επιλογής είναι η per-token accuracy (όχι η entity-level F1 του NER).

Token	Αληθές tag	Πρόβλεψη	Σωστό;
Wk	VB	NNP	×
to	TO	TO	✓
Date	NNP	VB	×
69,100	CD	CD	✓
Week	NNP	NN	×
Ago	NNP	RB	×
58,100	CD	CD	✓
Year	NNP	NN	×
Ago	NNP	RB	×
30,800	CD	CD	✓

Πίνακας 2.3: Q6/Q3 POS - η χειρότερη πρόταση (test index 2010, 10 tokens, 6 λάθη, per-token accuracy 0.40).

Πρόκειται για ένα απόσπασμα πίνακα χρηματιστηριακών δεδομένων (“Wk to Date 69,100 Week Ago 58,100 Year Ago 30,800”), δηλαδή κείμενο τηλεγραφικού/πινακοειδούς ύφους χωρίς κανονική συντακτική δομή. Το μοντέλο σωστά αναγνωρίζει όλα τα αριθμητικά ως CD, αλλά αποτυγχάνει στις κεφαλαιοποιημένες συντομογραφίες: το “Wk” (συντομογραφία του “Week”, εδώ ετικετοποιημένο VB) προβλέπεται NNP, το “Date” (NNP) ως ρήμα VB, και τα επαναλαμβανόμενα “Week” / “Year” / “Ago” (όλα NNP στο gold, ως μέρη επικεφαλίδων στήλης) ως κοινά ουσιαστικά NN ή επιρρήματα RB. Το σφάλμα είναι αναμενόμενο: τέτοιες τηλεγραφικές επικεφαλίδες είναι εκτός κατανομής για ένα μοντέλο εκπαιδευμένο σε ρέοντα ειδησεογραφικό λόγο, και η κεφαλαιοποίηση από μόνη της οδηγεί το μοντέλο σε κύρια ονόματα/κοινά ουσιαστικά αντί της ασυνήθιστης gold επισημείωσης.

Στην επινοημένη πρόταση το μοντέλο κάνει ένα μόνο λάθος: το “startup” (κοινό ουσιαστικό NN) προβλέπεται ως κύριο όνομα NNP - εύλογο σφάλμα, αφού το “startup” βρίσκεται εδώ σε θέση προσδιοριστικού πριν από το κύριο όνομα “Helios”, δομή που συχνά υποδηλώνει κύριο όνομα. Όλα τα υπόλοιπα tokens, συμπεριλαμβανομένων των εφευρημένων ονομάτων “Helios” και “KronosAI” (σωστά NNP) και των επιθέτων εθνικότητας “Greek” / “Bavarian” (σωστά JJ), επισημειώνονται ορθά.

Token	Αληθές tag	Πρόβλεψη	Σωστό;
Greek	JJ	JJ	✓
startup	NN	NNP	×
Helios	NNP	NNP	✓
bought	VBD	VBD	✓
Bavarian	JJ	JJ	✓
rival	NN	NN	✓
KronosAI	NNP	NNP	✓
in	IN	IN	✓
Berlin	NNP	NNP	✓
yesterday	NN	NN	✓
for	IN	IN	✓
2	CD	CD	✓
billion	CD	CD	✓
euros	NNS	NNS	✓
.	.	.	✓

Πίνακας 2.4: Q6/Q3 POS - η επινοημένη πρόταση (ίδια με του Μέρους Α), 15 tokens, 1 λάθος, per-token accuracy 0.933.

2.3 Text chunking

Αλλαγές στον κώδικα. Η εργασία αλλάζει από NER σε text chunking αντικαθιστώντας τη στήλη ετικετών από *ner* σε *chunk* (*tag_column = "chunk"*) και θέτοντας *num_labels = 20* (BIO tag set των φραστικών τύπων: NP, VP, PP, ADJP, ADVP κ.λπ.). Επειδή το chunking έχει spans φράσεων, οι entity-level μετρικές του *seqeval* εφαρμόζονται κανονικά (όπως στο NER). Τα υπόλοιπα μένουν αμετάβλητα.

Μετρική	Μέση τιμή	Τυπική απόκλιση
Token-level micro accuracy	0.9518	0.0012
Token-level macro accuracy	0.5944	0.0021
Entity-level (chunk) micro F1	0.9024	0.0025
Entity-level (chunk) macro F1	0.6274	0.0012
Χρόνος εκπαίδευσης ανά σπόρο (s)	3135.7	16.1

Πίνακας 2.5: Q7 - text chunking, μέσος όρος $\pm$ τυπική απόκλιση πάνω σε seeds [42, 43, 44] (τοπικά, MPS).

Σχόλιο. Η chunk-level micro F1 (0.9024) είναι στο ίδιο επίπεδο με την NER micro F1 του Q1 (0.8977). Η μεγάλη απόσταση micro--macro (micro 0.90 έναντι macro 0.63 στα spans) οφείλεται στην έντονη ανισορροπία των φραστικών τύπων: οι NP και VP φράσεις είναι συντριπτικά συχνότερες, ενώ σπάνιοι τύποι (π.χ. CONJP, INTJ, LST) εμφανίζονται ελάχιστα και ρίχνουν τον macro μέσο όρο. Η token-level macro accuracy (0.59) αντανακλά την ίδια ανισορροπία σε επίπεδο tag.

2.3.1 Chunking - Ανάλυση σφαλμάτων

Για το seed 42 (entity-level micro F1 0.9060), από τις 735 υποψήφιες προτάσεις με ≥ 10 tokens και ≥ 1 λάθος, επιλέγεται αυτή με τη χαμηλότερη per-sentence entity-level (chunk) F1.

Token	Αληθές tag	Πρόβλεψη	Σωστό;
1.	B-NP	B-NP	✓
FC	I-NP	I-NP	✓
Cologne	I-NP	I-NP	✓
16	I-NP	I-NP	✓
8	I-NP	I-NP	✓
2	I-NP	I-NP	✓
6	I-NP	I-NP	✓
31	I-NP	I-NP	✓
27	I-NP	I-NP	✓
26	B-NP	I-NP	×

Πίνακας 2.6: Q7/Q3 chunking στη χειρότερη πρόταση (test index 606, 10 tokens, 1 λάθος, per-sentence chunk F1 = 0).

Η πρόταση είναι μια γραμμή βαθμολογικού πίνακα ποδοσφαίρου ("1. FC Cologne 16 8 2 6 31 27 26": ομάδα και ακολουθία αριθμητικών --- αγώνες, νίκες, ισοπαλίες, ήττες, γκολ υπέρ/κατά, βαθμοί). Το μοντέλο κάνει ένα μόνο λάθος, στο τελευταίο token "26": η gold επισημείωση το θεωρεί αρχή νέας ονομαστικής φράσης (B-NP, ξεχωριστή στήλη "βαθμοί"), ενώ το μοντέλο το προβλέπει ως I-NP, δηλαδή συνεχίζει τη μία μεγάλη NP φράση "1. FC Cologne 16 8 ...27 26". Αν και 9 από τα 10 tokens είναι σωστά (token accuracy 90%), η entity-level F1 της πρότασης καταρρέει στο 0: με όρους seqeval, η προβλεπόμενη ενιαία φράση δεν ταυτίζεται με καμία από τις δύο gold φράσεις (έχει λάθος όριο τέλους), οπότε και οι δύο gold φράσεις μετρώνται ως false negatives και η προβλεφθείσα ως false positive.

Παρατήρηση. Είναι ακριβώς το ίδιο μοτίβο **σφάλματος ορίου** με την πρόταση του Μέρους Α (§1.3, "Asian Cup"): ένα μόνο λανθασμένο όριο span μηδενίζει την entity-level F1 της πρότασης. Και στις δύο περιπτώσεις το κείμενο είναι αθλητικού/πινακοειδούς ύφους ακολουθίες αριθμών χωρίς κανονική συντακτική δομή, όπου ο διαχωρισμός των φράσεων εξαρτάται από σύμβαση δύσκολα ανακτήσιμη από τα συμφραζόμενα.

Στην επινοημένη πρόταση το μοντέλο τεμαχίζει άψογα και τα 15 tokens (F1 = 1.0): αναγνωρίζει τις ονομαστικές φράσεις "Greek startup Helios", "Bavarian rival KronosAI", "Berlin", "yesterday", "2 billion euros", τη ρηματική φράση "bought" και τις προθετικές "in" / "for". Όπως και στο NER (Μέρος Α), το μοντέλο χειρίζεται σωστά τα εφευρημένα ονόματα "Helios" και "KronosAI" μέσα στις NP φράσεις, στηριζόμενο στη συντακτική θέση και όχι στην απομνημόνευση. Η ίδια επινοημένη πρόταση χρησιμοποιείται και στα τρία tasks (NER / POS / chunking), επιτρέποντας άμεση like-for-like σύγκριση της συμπεριφοράς του μοντέλου ανά εργασία.

Token	Αληθές tag	Πρόβλεψη	Σωστό;
Greek	B-NP	B-NP	✓
startup	I-NP	I-NP	✓
Helios	I-NP	I-NP	✓
bought	B-VP	B-VP	✓
Bavarian	B-NP	B-NP	✓
rival	I-NP	I-NP	✓
KronosAI	I-NP	I-NP	✓
in	B-PP	B-PP	✓
Berlin	B-NP	B-NP	✓
yesterday	B-NP	B-NP	✓
for	B-PP	B-PP	✓
2	B-NP	B-NP	✓
billion	I-NP	I-NP	✓
euros	I-NP	I-NP	✓
.	O	O	✓

Πίνακας 2.7: Q7/Q3 chunking στην επινοημένη πρόταση (ίδια με Μέρη A/B), 15 tokens, 0 λάθη, per-sentence chunk F1 = 1.0.

2.4 Μοντέλο RoBERTa-base

Αλλαγές στον κώδικα. Ο κορμός *bert-base-uncased* αντικαθίσταται από *roberta-base* (ίδια κλίμακα, ≈ 125 M παράμετροι, 12 encoder layers). Η κρίσιμη αλλαγή είναι στον tokenizer: η RoBERTa χρησιμοποιεί byte-level BPE που είναι ευαίσθητη στα κενά, οπότε ο tokenizer αρχικοποιείται με `add_prefix_space=True` ώστε η τμηματοποίηση προ-διαχωρισμένων (pre-tokenized) λέξεων του CoNLL να είναι συνεπής. Η αντιστοίχιση ετικετών μέσω `word_ids()` και η λογική `align_label` παραμένουν αμετάβλητες. Η εργασία παραμένει NER (9 κλάσεις).

Μετρική	Μέση τιμή	Τυπική απόκλιση
Token-level micro accuracy	0.9825	0.0005
Token-level macro accuracy	0.9205	0.0038
Entity-level micro F1	0.9146	0.0032
Entity-level macro F1	0.8991	0.0016
Χρόνος εκπαίδευσης ανά σπόρο (s)	3303.5	48.0

Πίνακας 2.8: Q8 - NER με *roberta-base*, μέσος όρος $\pm$ τυπική απόκλιση πάνω σε seeds [42, 43, 44] (τοπικά, MPS).

Σύγκριση με το Ερώτημα 1. Η RoBERTa βελτιώνει σταθερά το BERT σε κάθε μετρική: entity-level micro F1 $0.8977 \rightarrow 0.9146$ (+1.7 ποσοστιαίες μονάδες), entity-level macro F1 $0.8810 \rightarrow 0.8991$ (+1.8 μονάδες). Η βελτίωση είναι μεγαλύτερη από την τυπική απόκλιση και των δύο μοντέλων, οπότε είναι στατιστικά ουσιώδης και όχι θόρυβος

seed. Η υπεροχή αποδίδεται στις γνωστές διαφορές προ-εκπαίδευσης της RoBERTa: περισσότερα δεδομένα, δυναμικό masking, απουσία του next-sentence-prediction στόχου και byte-level BPE λεξιλόγιο, που συνολικά παράγουν ισχυρότερες αναπαραστάσεις token. Ο χρόνος εκπαίδευσης είναι ουσιαστικά ίδιος (3304 έναντι 3256 s στο Q1, ίδιο υλικό MPS).

Σύνοψη του Μέρους B (NER παραλλαγές). Ο Πίνακας 2.9 συγκεντρώνει τις τρεις NER παραλλαγές για άμεση σύγκριση στην entity-level micro F1.

Παραλλαγή	Μοντέλο / ρύθμιση	Entity micro F1
Q1 (baseline)	bert-base-uncased, πλήρες fine-tuning	0.8977 ± 0.0039
Q5	bert-base-uncased, παγωμένος κορμός	0.2487 ± 0.0152
Q8	roberta-base, πλήρες fine-tuning	0.9146 ± 0.0032

Πίνακας 2.9: NER παραλλαγές του Μέρους B στο test split του *CoNLL-2003* (μέσος όρος $\pm$ τυπική απόκλιση, seeds [42, 43, 44]).

Κεφάλαιο 3

Μέρος Γ - Zero-shot αναγνώριση οντοτήτων με decoder-only LLMs

Στο Μέρος Γ εξετάζεται η εναλλακτική προσέγγιση χωρίς εκπαίδευση: αντί να εκπαιδευτεί ταξινομητής, ένα προ-εκπαιδευμένο decoder-only LLM καλείται μέσω HTTP και του ζητείται, με zero-shot prompting, να επισημειώσει τα tokens. Η αξιολόγηση γίνεται στα πρώτα 200 παραδείγματα του test split του CoNLL-2003. Σε κάθε κλήση δίνεται μία μόνο πρόταση.

Κοινό πρωτόκολλο. Όλα τα μοντέλα μοιράζονται την ίδια μηχανή: (i) ένα prompt (βλ. παρακάτω), (ii) έναν parser που εξάγει το JSON array {token, tag} από την απάντηση και ανακατασκευάζει την ετικέτα ανά token στο BIO σχήμα, αντιστοιχίζοντας στις προδιαχωρισμένες λέξεις του CoNLL, (iii) γραμμή-ατομική αποθήκευση κάθε απάντησης σε *sentences.jsonl* με resume κατά την επανεκκίνηση (παράλειψη ήδη αποθηκευμένων *sentence_idx*), και (iv) έναν aggregator που υπολογίζει token-level (*sklearn*) και entity-level (*seqeval*) μετρικές. Όταν μια απάντηση δεν αναλύεται σε έγκυρο JSON, καταγράφεται ως *parse_failed* και η πρόταση εξαιρείται από τις μετρικές --- οπότε το *completed_count* (≤ 200) είναι το πλήθος των προτάσεων στις οποίες υπολογίζονται οι μετρικές.

Τα τρία prompts. Δοκιμάστηκαν τρεις παραλλαγές προτροπής:

- **v1_minimal** - ελάχιστες οδηγίες: ορισμός του task, απαρίθμηση των 9 ετικετών, και απαίτηση για καθαρό JSON array.
- **v2_strict_json** - ίδιο με το v1 συν ένα ρητό παράδειγμα μορφής εξόδου και ρητή απαίτηση ότι το πλήθος των αντικειμένων πρέπει να ισούται με το πλήθος των tokens (έμφαση στην αυστηρότητα μορφής).
- **v3_with_glossary** - ίδιο με το v1 συν ένα γλωσσάρι που εξηγεί τη σημασία κάθε ετικέτας (B-PER, I-PER, B-ORG, ...) με σύντομα παραδείγματα.

Το βασικό (v1_minimal) prompt είναι:

You are a Named Entity Recognition system using the CoNLL-2003 BIO scheme.

Tag each token with one of: O, B-PER, I-PER, B-ORG, I-ORG, B-LOC, I-LOC, B-MISC, I-MISC.

Return ONLY a JSON array of {"token": "...", "tag": "..."} objects, in the same order as the input. Do not add commentary, markdown fences, or extra keys.

3.1 Llama-3.1-8B-Instant (Groq)

Ο Πίνακας 3.1 δείχνει την επίδοση του *llama-3.1-8b-instant* και στις τρεις παραλλαγές prompt.

Prompt	Tok-micro	Tok-macro	Ent micro F1	Ent macro F1	Καλυφθείσες
v1_minimal	0.8929	0.5441	0.5910	0.4711	193/200
v2_strict_json	0.8694	0.4697	0.5059	0.3973	171/200
v3_with_glossary	0.9063	0.5937	0.6557	0.4976	192/200

Πίνακας 3.1: Q9 - Llama-3.1-8B zero-shot NER στα πρώτα 200 test παραδείγματα, ανά prompt. ``Καλυφθείσες`` = προτάσεις χωρίς parse failure στις οποίες υπολογίζονται οι μετρικές.

Σχόλιο. Το μικρό 8B μοντέλο είναι *έντονα ευαίσθητο στο prompt*: το γλωσσάρι (v3) ανεβάζει την entity micro F1 κατά +6.5 μονάδες έναντι του minimal (0.6557 vs 0.5910), ενώ αντιδιδιαισθητικά η αυστηρή μορφή (v2) τη ρίχνει κατά 8.5 μονάδες (0.5059) και προκαλεί τα περισσότερα parse failures (29/200): η πρόσθετη πολυπλοκότητα της οδηγίας μορφής μπερδεύει το μικρό μοντέλο αντί να το βοηθήσει. Ακόμη και στην καλύτερη παραλλαγή, η entity F1 (0.66) υπολείπεται κατά ≈ 24 μονάδες του fine-tuned BERT (Q1).

3.2 Llama-3.3-70B-Versatile (Groq)

Prompt	Tok-micro	Tok-macro	Ent micro F1	Ent macro F1	Καλυφθείσες
v1_minimal	0.9600	0.8843	0.8565	0.7335	200/200
v2_strict_json	0.9680	0.9661	0.8744	0.7888	36/200

Πίνακας 3.2: Q10 - Llama-3.3-70B zero-shot NER. Το v1_minimal καλύπτει και τις 200 προτάσεις (0 parse failures). Το v2_strict_json διακόπηκε στις 36 προτάσεις λόγω ορίων ρυθμού (Groq TPD), οπότε δεν είναι άμεσα συγκρίσιμο.

Σχόλιο. Το 70B είναι ποιοτικά διαφορετικό από το 8B: με το απλό v1_minimal πετυχαίνει ήδη entity micro F1 0.8565 με μηδέν parse failures και πλήρη κάλυψη (200/200), δηλαδή είναι ανθεκτικό στο prompt και στη μορφή. Η κλιμάκωση από 8B σε 70B αποφέρει +20 έως +27 μονάδες entity F1 --- η ικανότητα zero-shot NER συσχετίζεται ισχυρά με το μέγεθος του μοντέλου. (Η στήλη v2 με 36/200 προτάσεις δίνεται μόνο για

πληρότητα· το μεγαλύτερο *tok-macro* εκεί οφείλεται στο μικρό, μη-αντιπροσωπευτικό δείγμα.)

Χρονικό κόστος. Το ακριβές wall-clock ανά κλήση δεν καταγράφηκε, αλλά η συμπεριφορά είναι ποιοτικά σαφής: η zero-shot προσέγγιση απαιτεί μία κλήση HTTP ανά πρόταση με υποχρεωτική καθυστέρηση μεταξύ κλήσεων λόγω ορίων ρυθμού, οπότε ο συνολικός χρόνος κυριαρχείται από το rate limiting και όχι από τον υπολογισμό. Το 8B-instant είναι το ταχύτερο/φθηνότερο· το 70B είναι αργότερο και κατά την εκτέλεση εξάντλησε το ημερήσιο όριο tokens (TPD) του Groq, ενεργοποιώντας fallback σε OpenRouter για τις τελευταίες κλήσεις του v1_minimal.

3.3 Bonus επεκτάσεις - GLM-4.7-Flash και Gemini

Με το ίδιο πρωτόκολλο (prompt v1_minimal, πρώτα 200 test παραδείγματα) εκτελέστηκαν δύο ακόμη μοντέλα: το *GLM-4.7-Flash* (Z.ai, με απενεργοποιημένο το *thinking*) και το *Gemini-2.5-Flash-Lite* (Google AI Studio).

Μοντέλο	Tok-micro	Tok-macro	Ent micro F1	Ent macro F1	Καλυφθείσες
GLM-4.7-Flash	0.9569	0.7366	0.8229	0.6966	197/200
Gemini-2.5-Flash-Lite	0.9912	0.7975	0.9561	0.8728	40/200

Πίνακας 3.3: Bonus zero-shot επεκτάσεις, prompt v1_minimal. **Προσοχή:** το Gemini σταμάτησε στις 40/200 προτάσεις λόγω του ορίου δωρεάν χρήσης (20 RPD), οπότε η εξαιρετική του επίδοση είναι άνω φράγμα αναφοράς σε μικρό δείγμα, όχι άμεσα συγκρίσιμο μέγεθος.

Σχόλιο. Το GLM-4.7-Flash (0.8229 σε 197/200) τοποθετείται ανάμεσα στο 70B και στο 8B Llama. Το Gemini πετυχαίνει εντυπωσιακή entity F1 (0.9561), αλλά μόνο σε 40 προτάσεις: το μικρό δείγμα και το φράγμα του δωρεάν tier δεν επιτρέπουν δίκαιη σύγκριση με τα υπόλοιπα - το παραθέτουμε ως ένδειξη ότι ένα σύγχρονο frontier-grade μικρό μοντέλο μπορεί να πλησιάσει το fine-tuned επίπεδο zero-shot, χωρίς να το θεωρούμε αποδεδειγμένο εδώ.

3.4 Συνολική σύγκριση και συμπεράσματα

Μεθοδολογική επιφύλαξη. Η σύγκριση δεν είναι αυστηρά like-for-like: οι encoder γραμμές αξιολογούνται στο πλήρες test set (3,453 προτάσεις, μέσος 3 seeds), ενώ οι decoder γραμμές σε μία εκτέλεση στα πρώτα 200 παραδείγματα, και μάλιστα μόνο στις προτάσεις που αναλύθηκαν επιτυχώς. Μία πλήρως ισοδύναμη σύγκριση θα απαιτούσε επανα-αξιολόγηση των Q1/Q8 στις ίδιες 200 προτάσεις. Παρόλα αυτά, τα μεγέθη των διαφορών είναι αρκετά μεγάλα ώστε τα ποιοτικά συμπεράσματα να είναι ασφαλή.

Προσέγγιση	Μοντέλο (ρύθμιση)	Ent micro F1	Δείγμα
Fine-tune (Q8)	roberta-base (3 seeds)	0.9146	full test
Fine-tune (Q1)	bert-base-uncased (3 seeds)	0.8977	full test
Zero-shot (Q10)	Llama-3.3-70B, v1	0.8565	200
Zero-shot bonus	GLM-4.7-Flash, v1	0.8229	197
Zero-shot (Q9)	Llama-3.1-8B, v3 (best prompt)	0.6557	192
Zero-shot (Q9)	Llama-3.1-8B, v1	0.5910	193
Αναφορά (μικρό δείγμα, μη συγκρίσιμο):			
Zero-shot bonus	Gemini-2.5-Flash-Lite, v1	0.9561	40

Πίνακας 3.4: Συγκεντρωτική σύγκριση entity-level micro F1 στο test split του *CoNLL-2003*. Οι fine-tuned γραμμές είναι μέσος όρος 3 seeds στο πλήρες test set (3.453 προτάσεις)· οι zero-shot γραμμές είναι μία εκτέλεση στα πρώτα 200 παραδείγματα. Δεν πρόκειται για αυστηρά ισοδύναμη σύγκριση (βλ. παρακάτω).

Encoder fine-tuning έναντι decoder zero-shot. Το κεντρικό εύρημα είναι ότι το fine-tuning encoder μοντέλων υπερτερεί του zero-shot, παρά την τεράστια διαφορά μεγέθους: το fine-tuned roberta-base (≈ 125 M παράμετροι) πετυχαίνει 0.9146, ενώ το zero-shot Llama-3.3-70B (70 B παράμετροι, $\approx 560\times$ μεγαλύτερο) μένει στο 0.8565 (διαφορά ≈ 6 μονάδων υπέρ του πολύ μικρότερου), αλλά εκπαιδευμένου σε *in-domain* δεδομένα, μοντέλου. Η γνώση της ακριβούς σύμβασης επισημείωσης του CoNLL (π.χ. ότι τα εθνικά επίθετα είναι MISC, τα όρια των spans) μαθαίνεται από τα δεδομένα και δύσκολα μεταφέρεται πλήρως μέσω prompt.

Πόσο ανταγωνιστικά είναι τα decoder-only μοντέλα; Σε αυτό το *in-domain* benchmark με κλειστό σύνολο ετικετών, τα zero-shot decoders δεν είναι ανταγωνιστικά με τα fine-tuned encoders: υπολείπονται κατά ≥ 6 μονάδες ακόμη και στα 70 B, ενώ φέρουν δύο επιπλέον λειτουργικά κόστη που οι encoders δεν έχουν :

- ευθραυστότητα μορφής (parse failures: η κάλυψη πέφτει κάτω από 200)
- χρονικό κόστος ανά κλήση κυριαρχούμενο από όρια ρυθμού.

Από την άλλη, έχουν ένα ουσιώδες πλεονέκτημα: δεν απαιτούν καθόλου επισημειωμένα δεδομένα ή εκπαίδευση. Επιπλέον, η κλιμάκωση (8B $\rightarrow$ 70B) και η ποιότητα του prompt βελτιώνουν δραματικά τα αποτελέσματα, και σύγχρονα μοντέλα όπως το Gemini υποδεικνύουν ότι το χάσμα μπορεί να κλείνει. Συμπερασματικά: όταν υπάρχουν επισημειωμένα δεδομένα και απαιτείται μαζική/ επαναλαμβανόμενη επισημείωση, τα fine-tuned encoders είναι σαφώς προτιμότερα (το κόστος εκπαίδευσης αποσβένεται και το inference είναι φθηνό)· τα zero-shot decoders λάμπουν σε σενάρια χωρίς δεδομένα ή για γρήγορη πρωτοτυποποίηση.